

## Скачать любой датасет из списка ниже с сайта Kaggle.com (достаточно большой) Загрузить этот датасет в HDFS в свою домашнюю папку



## Создать собственную базу данных в HIVE

```
create external table lesson4_student9_11.engagement
(source_id int,
source_name string,
author string,
title string,
description string,
url string,
url_to_image string,
published_at date,
content string,
top_article boolean,
engagement_reaction_count int,
engagement_comment_count int,
engagement_share_count int,
engagement_comment_plugin_count int
)
ROW FORMAT serde 'org.apache.hadoop.hive.serde2.lazy.LazySimpleSerDe'
WITH SERDEPROPERTIES ('field.delim' = ',')
location "/user/hive/warehouse/lesson4_student9_11.db/"
tblproperties("skip.header.line.count"="1")
-- drop table lessons9_4.customers;
select * from lesson4_student9_11.engagement limit 100;
```

## Создать таблицы внутри базы данных с использованием всех загруженных файлов. Один файл – одна таблица.



Сделать любой отчет по загруженным данным используя групповые и агрегатные функции.

- среднее по количество пересолов новостей

SELECT avg(engagement\_share\_count) from lesson4\_student9\_11.engagement;



```
Сделать любой отчет по загруженным данным используя JOIN.
```

```
create table lesson4_student9_11.engagement_new AS
select source_id, source_name from lesson4_student9_11.engagement;
create table lesson4_student9_11.engagement_new_2 AS
select source_id, author from lesson4_student9_11.engagement;
SELECT t1.source_id, t1.source_name, t2.author from
lesson4_student9_11.engagement_new t1
JOIN lesson4_student9_11.engagement_new_2 t2
ON t1.source_id = t2.source_id
create table lesson4_student9_11.engagement_new AS
select source_id, source_name from lesson4_student9_11.engagement;
create table lesson4_student9_11.engagement_new_2 AS
select source_id, author from lesson4_student9_11.engagement;
SELECT t1.source_id, t1.source_name, t2.author from lesson4_student9_11.engagement_new t1
 JOIN lesson4_student9_11.engagement_new_2 t2
ON t1.source_id = t2.source_id
NFO : Compiling command(queryId=hive_20201203115454_c54dd36f-9414-42a6-ae1e-ef1196d3j0b_1604591611666_0907
:1.source_name, t2.author from lesson4_student9_11.engagement_new t1
IOIN lesson4_student9_11.engagement_new_2 t2
N t1.source_id = t2.source_id
Query History Q 🛱 Saved Queries Q
                                        Results (100+) Q ~
        t1.source_id
                                                              t2.author
                               t1.source_name
         O
                               reuters
                                                              Reuters
        1
                               the-irish-times
                                                              The Irish Times
```

the-irish-times

The Irish Times

2